




3. BÖLÜM

SINIFLANDIRMA





❖ Sınıflandırma işlemi

- ✓ Sınıflandırma tanımı
- ✓ Sınıflandırma uygulamaları

❖ Sınıflandırma yöntemleri

- ✓ Karar ağaçları
- ✓ Yapay sinir ağları
- ✓ Bayes sınıflandırıcılar
- ✓ Bayes ağları





Sınıflandırma (Classification)

❖ Sınıflandırma (classification) problemi:

✓ Nesnelerden oluşan veri kümesi (öğrenme kümesi):

$$D=\{t_1,t_2,\dots,t_n\}$$

✓ Her nesne niteliklerden oluşuyor, niteliklerden biri sınıf bilgisi

❖ Sınıf niteliğini belirlemek için diğer nitelikleri kullanarak bir **model bulma**

❖ Öğrenme kümesinde yer almayan nesneleri (**test kümesi**) mümkün olan en iyi şekilde doğru sınıflara atamak

❖ Sınıflandırma=ayrık değişkenler için öngöründe (prediction) bulunmak.



❖ **Amaç:** Yeni bir kayıt geldiğinde, bu kaydı geliştirilen modeli kullanılarak mümkün olduğunca doğru bir sınıfa atamak.

- ✓ Verinin dağılımına göre bir model bulunur.
- ✓ Bulunan model, başarımı belirlendikten sonra niteliğin gelecekteki değeri,
- ✓ Ya da bilinmeyen değerini tahmin etmek için kullanılır.
 - Model başarımı: doğru sınıflandırılmış sınıfa kümesi örneklerinin oran.




❖ Veri madenciliği uygulamasında:

✓ Ayırık nitelik değerlerini tahmin etmek: **sınıflandırma**

✓ Sürekli nitelik değerlerini tahmin etmek: **öngörü**

✓ **Sınıflandırma:** hangi topun hangi sepete koyulabileceği

✓ **Öngörü:** Topun ağırlığı





Danışmanlı & Danışmansız Öğrenme

❖ **Danışmanlı (Gözetimli, Supervised) öğrenme= sınıflandırma**

✓ **Sınıfların sayısı ve hangi nesnenin hangi sınıfta olduğu biliniyor.**



❖ **Danışmansız (Gözetimsiz, Unsupervised) öğrenme= kümeleme (clustering)**

✓ **Hangi nesnenin hangi sınıfta olduğu bilinmiyor. Genelde sınıf sayısı bilinmiyor**





Sınıflandırma Uygulamaları

- ❖ Kredi başvurusu değerlendirme,
- ❖ Kredi kartı harcamasının sahtekarlık olup olmadığına karar verme,
- ❖ Hastalık teşhisi,
- ❖ Ses tanıma,
- ❖ Karakter tanıma,
- ❖ Gazete haberlerini konularına göre ayırma,
- ❖ Kullanıcı davranışları belirleme.





Sınıflandırma için Veri Hazırlama

❖ Veri dönüşümü:

- ✓ Sürekli nitelik değeri ayrık hale getirilir
- ✓ Normalizasyon $[-1, \dots, 1]$, $[0, \dots, 1]$

❖ Veri temizleme:

- ✓ Gürültüyü azaltma
- ✓ Gereksiz nitelikleri silme



Sınıflandırma İşlemi

❖ Sınıflandırma işlemi üç aşamadan oluşur:

1. Model oluşturma
2. Model değerlendirme
3. Modeli kullanma





Sınıflandırma İşlemi: Model Oluşturma

1. Model Oluşturma:

- ❖ Her nesnenin sınıf etiketi olarak tanımlanan niteliğinin belirlediği bir sınıfta olduğu varsayılır
- ❖ Model oluşturmak için kullanılan nesnelerin oluşturduğu veri kümesi öğrenme kümesi olarak tanımlanır
- ❖ Model farklı biçimlerde ifade edilebilir
 - ✓ IF – THEN – ELSE kuralları ile
 - ✓ Karar ağaçları ile
 - ✓ Matematiksel formüller ile



10



3.Bölüm

Sınıflandırma İşlemi: Model Değerlendirme

2. Model Değerlendirme:

- ❖ Modelin başarımı (doğruluğu) sinama kümesi örnekleri kullanılarak belirlenir.
- ❖ Sınıf etiketi bilinen bir sinama kümesi örneği model kullanılarak belirlenen sınıf etiketiyle karşılaştırılır.
- ❖ Modelin doğruluğu, doğru sınıflandırılmış sinama kümesi örneklerinin toplam sinama kümesi örneklerine oranı olarak belirlenir.
- ❖ Sinama kümesi model öğrenirken kullanılmaz.



Sınıflandırma İşlemi: Modeli Kullanma

3. Modeli kullanma:

- ❖ Model daha önce görülmemiş örnekleri sınıflandırmak için kullanılır
- ✓ Örneklerin sınıf etiketlerini tahmin etme
- ✓ Bir niteliğin değerini tahmin etme



12




3.Bölüm

Tid	Nit1	Nit2	Nit3	Sınıf
1	1	Büyük	125K	0
2	0	Orta	100K	0
3	0	Küçük	70K	0
4	1	Orta	120K	0
5	0	Büyük	95K	1
6	0	Orta	60K	0
7	1	Büyük	220K	0
8	0	Küçük	85K	1
9	0	Orta	75K	0
10	0	Küçük	90K	1

Öğrenme
Kümesi

Tid	Nit1	Nit2	Nit3	Sınıf
11	0	Küçük	55K	?
12	1	Orta	80K	?
13	1	Büyük	110K	?
14	0	Küçük	95K	?
15	0	Büyük	67K	?

Sınama
Kümesi





Sınıflandırıcı Başarımını Değerlendirme

Doğru sınıflandırma başarısı

❖ Hız

- ✓ Modeli oluşturmak için gerekli süre
- ✓ Sınıflandırma yapmak için gerekli süre

❖ Kararlı olması

- ✓ Veri kümesinde gürültülü ve eksik nitelik değerleri olduğu durumlarda da iyi sonuç vermesi

❖ Ölçeklenebilirlik

- ✓ Büyük miktarda veri kümesi ile çalışabilmesi

❖ Anlaşılabilir olması

- ✓ Kullanıcı tarafından yorumlanabilir olması

❖ Kuralların yapısı

- ✓ Birbiriyle örtüşmeyen kurallar



Sınıflandırma Yöntemleri

- ❖ Karar Ağaçları (Decision Trees)
- ❖ Yapay Sinir Ağları (Artificial Neural Networks)
- ❖ Bayes Sınıflandırıcılar (Bayes Classifier)
- ❖ İlişki Tabanlı Sınıflandırıcılar (Association-based Classifier)
- ❖ K-en Yakın Komşu Yöntemi (K- Nearest Neighbor Method)
- ❖ Destek Vektör Makineleri (Support Vector Machines)
- ❖ Genetik Algoritmalar (Genetic Algorithms)
- ❖ ...

Karar Ağaçları



❖ Karar Ağacı

- ✓ Yaygın kullanılan öngörü yöntemlerinden bir tanesidir.
- ✓ Ağaçtaki her düğüm bir özellikteki testi gösterir.
- ✓ Düğüm dalları testin sonucunu belirtir.
- ✓ Ağaç yaprakları sınıf etiketlerini içerir.

❖ Karar ağacı çıkarımı iki aşamadan oluşur


- ✓ Ağaç inşası
 - Başlangıçta bütün öğrenme örnekleri kök düğümündedir.
 - Örnekler seçilmiş özelliklere tekrarlamalı olarak göre bölünür.
- ✓ Ağaç Temizleme (Budama) (Tree pruning)
 - Gürültü ve istisna kararları içeren dallar belirlenir ve kaldırılır.

❖ Karar ağacı kullanımı: Yeni bilinmeyen örneğin sınıflandırılması

- ✓ Bilinmeyen örneğin özellikleri karar ağacında test edilerek sınıfı bulunur.



Bir Kredi Kartı Kampanyasında Yeni Bir Örneğin Sınıflandırılması





Karar Ağacı Yöntemleri

❖ Karar ağacı oluşturma yöntemleri genel olarak iki aşamadan oluşur:

✓ 1. Ağaç oluşturma

- En başta bütün öğrenme kümesi örnekleri kökte
- Seçilen niteliklere bağlı olarak örnek yinelemeli olarak bölünüyor.

✓ 2. Ağaç budama

- Öğrenme kümesindeki gürültülü verilerden oluşan ve sinama kümesinde hataya neden olan dalları silme (sınıflandırma başarımını artırır)



Karar Ağacı Oluşturma

❖ Yinelemeli işlem

- ✓ Ağaç bütün verinin oluşturduğu tek bir düğümle başlıyor
- ✓ Eğer örnekleri hepsi aynı sınıfa aitse düğüm yaprak olarak sonlanıyor ve sınıf etiketini alıyor.
- ✓ Eğer değilse örnekleri sınıflara en iyi bölecek olan nitelik seçiliyor.
- ✓ İşlem sona eriyor.
 - Örneklerin hepsi (çoğunluğu) aynı sınıfa ait,
 - Örnekleri bölecek nitelik kalmamış,
 - Kalan niteliklerin değerini taşıyan örnek yok.






Örnekleri En İyi Bölen Nitelik Hangisi?

❖ Bölmeden önce:

- ✓ 10 örnek C0 sınıfında
- ✓ 10 örnek C1 sınıfında

19



Hangisi daha iyi?



En iyi Bölme Nasıl Belirlenir?

- ❖ “Greedy” (aç gözlü) yaklaşım
 - ✓ Çoğunlukla aynı sınıfa ait örneklerin bulunduğu düğümler tercih edilir.
- ❖ Düğümün kalitesini ölçmek için bir yöntem

C0: 5
C1: 5

kalitesi düşük

C0: 9
C1: 1

kalitesi yüksek





En İyi Bölen Nitelik Nasıl Belirlenir?

- ❖ İyilik Fonksiyonu (Goodness Function)
- ❖ Farklı algoritmalar farklı iyilik fonksiyonları kullanabilir:
 - ✓ Bilgi kazancı (information gain): ID3, C4.5
 - Bütün niteliklerin ayrık değerler aldığı varsayılıyor.
 - Sürekli değişkenlere uygulamak için değişiklik yapılabilir.
 - ✓ Gini index (IBM IntelligentMiner)
 - Her nitelik ikiye bölünüyor.
 - Her nitelik için olası bütün ikiye bölünmeler sınanıyor.



Bilgi / Entropi

❖ $p_1, p_2, \dots, p_s$ toplamaları 1 olan olasılıklar. Entropi (Entropy)

$$H(p_1, p_2, \dots, p_s) = - \sum_{i=1}^s p_i \log(p_i)$$


❖ Entropi rastgeleliği, belirsizliği ve beklenmeyen durumun ortaya çıkma olasılığını gösterir.

❖ Sınıflandırmada


✓ Olayın olması beklenen bir durum

✓ Entropi=0

Entropi



$\log(p)$



$H(p, 1-p)$

- örnekler aynı sınıfa aitse entropi=0
- örnekler sınıflar arasında eşit dağılmışsa entropi=1
- örnekler sınıflar arasında rastgele dağılmışsa $0 < \text{entropi} < 1$

Örnek

- S veri kümesinde 14 örnek: C0 sınıfına ait 9, C1 sınıfına ait 5 örnek.

- Entropi

$$H(p_1, p_2, \dots, p_s) = - \sum_{i=1}^s p_i \log(p_i)$$

- $H(p_1, p_2) = - (9/14) \log_2 (9/14) - (5/14) \log_2 (5/14)$
 $= 0.940$



Bilgi Kazancı (ID3 / C4.5)



SON



- ❖ Bilgi kuramı kavramlarını kullanarak karar ağacı oluşturulur. Sınıflandırma sonucu için en az sayıda karşılaştırma yapmayı hedefler.
- ❖ Ağaç bir niteliğe göre dallandığında entropi ne kadar düşer?
- ❖ A niteliğinin S veri kümesindeki bilgi kazancı

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

Values(A), A niteliğinin alabileceği değerler, S_v , $A=v$ olduğu durumda S'nin altkümesi.